ДЗ 2. Журнал расписания

Задание 2. MCP-сервер

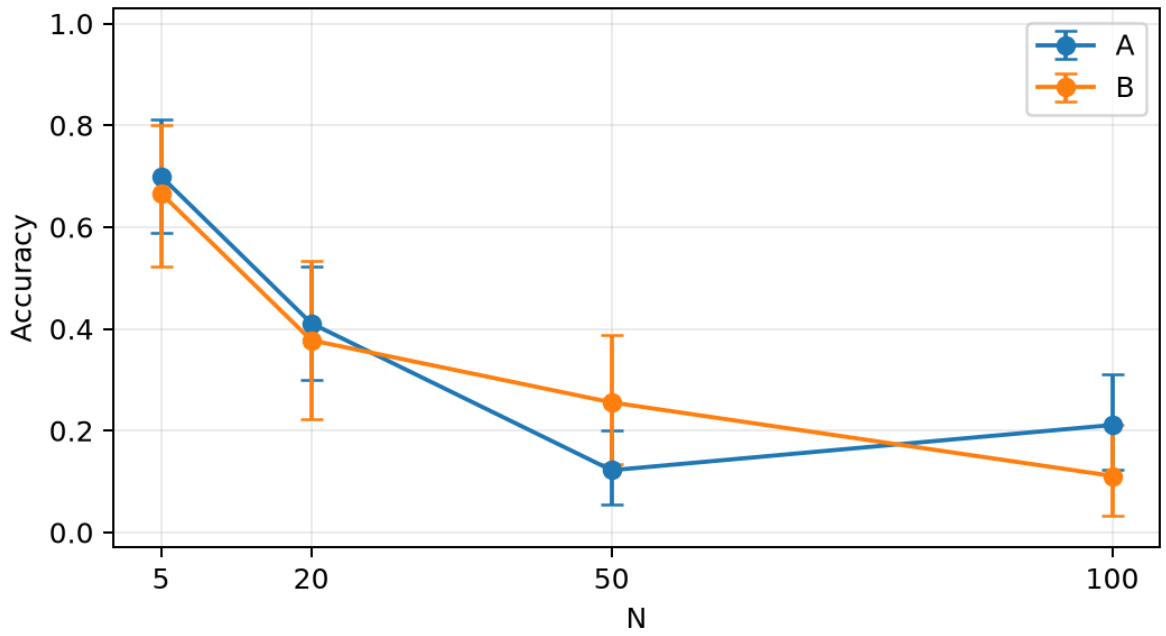
Реализованы schedule_search, schedule_get, schedule_free и schedule_add. Состояние хранится в SQLite; handle (main или second) передаётся каждым вызовом. MCP 2026-07-28: stateless, server/discover, _meta в запросах. У параметров есть description, закрытые значения заданы enum, лишние поля запрещены. Ошибки возвращают isError=true и подсказку. concise возвращает основные поля, detailed - все данные.

Проверка: 23 теста pytest прошли. MCP Inspector 2.10.1 проверил каталог, успешные вызовы всех четырёх инструментов и ошибку неизвестного id. Логи: logs/pytest.txt, logs/inspector.jsonl. Размеры ответов приведены в README.

Задание 3A. Выбор инструмента

Qwen3-0.6B, MLX, 4 бита, thinking выключен; temperature=0.7, top_p=0.8, top_k=20, лимит ответа 160 токенов. Пул: 4 своих + 96 сгенерированных инструментов, из них 24 близких по смыслу. 30 размеченных запросов, N=5/20/50/100, 3 запуска (seed=42/43/44). Всего 720 попыток. Наборы вложены и содержат четыре целевых инструмента; их состав одинаков для A и B.

A получает все N описаний. Для B локальный поиск автоматически выбирает top-5 по косинусной близости эмбеддингов paraphrase-multilingual-MiniLM-L12-v2. Модель получает описание поиска, выдачу и пять описаний. Оценивается имя инструмента в текстовом ответе. 95%-е интервалы: 10 000 бутстрэп-выборок запросов; три повтора каждого запроса сохраняются вместе. Ошибки и незавершённые попытки считаются неверными.



N	A: верно / 90	B: верно / 90	Recall@5	Токены A / B
5	63	60	100.0%	293 / 345
20	37	34	53.3%	804 / 323
50	11	23	53.3%	1885 / 321
100	19	10	30.0%	3589 / 310

Задание 3Б. Петли

20 задач по поиску занятия за одну из двух дат, по 3 повтора, 3 условия: всего 180 эпизодов. Первая дата намеренно не содержит искомого занятия, вторая содержит. schedule_search в 50% вызовов скрывает результат и возвращает []. Другие вызовы возвращают результат настоящего инструмента. Для одинаковых задач и повторов используется одинаковый seed генератора неисправностей.

Максимум 8 шагов на эпизод. Петля: не менее трёх одинаковых выполненных вызовов подряд либо A-B-A-B. LoopGuard взят из лекции: 3 одинаковых вызова в окне 6, чередование действий, 6 неизменных наблюдений. Первый сигнал передаётся модели; второй останавливает эпизод. В третьем условии пустой ответ заменён на «Ничего не найдено; попробуйте другое значение date», guard выключен.

Успех засчитывается только при финальном правильном id, который до этого действительно наблюдался. Шаг включает каждый запрос модели, в том числе неправильный JSON. Токены эпизода - сумма входных и выходных токенов всех его запросов, включая повторно переданную историю.

Условие	Эпизоды	Петли	Шаги	Токены	Успех
Пустой ответ	60 / 60	66.7%	8.00	4648	0.0%
Пустой + guard	60 / 60	60.0%	6.03	3316	0.0%
Подсказка	60 / 60	51.7%	8.00	4861	0.0%

Выводы

При N=100 точность A составила 21.1%, B - 11.1%. Входной контекст B меньше в 11.6 раза. Поиск уменьшает контекст, но пропуск правильного инструмента ограничивает итоговую точность.

Успех guard - 0.0%, подсказки - 0.0%. Средние шаги: guard 6.03, подсказка 8.00. Долю петель и затраты нужно оценивать отдельно: guard сигнализирует после возникновения повторов, поэтому обнаруженная петля остаётся в метрике даже после остановки. Различия здесь описательные, без проверки статистической значимости для условий с петлями.

Подсказка сильнее снижает долю петель: 51.7% против 60.0% с guard. Guard сильнее ограничивает шаги и токены. Ни один способ не повысил долю успеха: модель не завершала задачу через finish даже после получения верной записи. По этому прогону можно сравнивать петли и расходы, но нельзя утверждать улучшение успешности.

Полнота данных и бюджет

Сохранены 720 / 720 попыток выбора и 180 / 180 эпизодов. Ошибки API: выбор - 0, петли - 0; остановки по лимиту шагов - 140. Все включены в знаменатели. Использование токенов получено из usage локального сервера; точные значения и интервалы - results/*.csv. Эмбеддинги вычисляются локально: их токены записаны отдельно и не входят во входной контекст LLM. Расходы на API: $0, ключи не используются.

Первоначальный запуск с другим парсером: 95 / 180 эпизодов записаны, успех 0/180; остальные незавершены. Парсер отвергал JSON в Markdown, инструменты не исполнялись. Этот запуск сохранён в logs/parser_before_loops.jsonl и показан отдельно: после исправления повторён полный протокол. Неудачи основного прогона включены в таблицу выше.

Три угрозы валидности

1. Синтетический пул и только 30 вручную размеченных запросов: реальные формулировки и инструменты могут отличаться.
2. Одна маленькая модель, 4-битная квантизация и выбор имени текстом: выводы нельзя переносить на другие модели и native tool calling.
3. Задачи с петлями намеренно начинаются с пустой даты; подсказка особенно полезна в такой среде. Совпадение seed неисправностей не делает траектории одинаковыми после изменения действий.